

# Data Mining Howork2 作業模板

作業回答共 20 分，未繳交或未做答 0 分計算。

## 1. 方法選擇 (Method Selection) 4 分

這次我選擇的模型是 XGBoost，因為他在分類的模型上表現比較出眾。

相較於一般常見的 Logistic Regression 或 Decision Tree，XGBoost 屬於 Gradient Boosting 的模型，把很多弱分類器組合成一個強大的模型，而且能更好的處理非線性且特徵關係複雜的分類問題。

而 Gradient Boosting 也有許多方法像是 LightGBM 及 CatBoost ...，但在我所處理後的資料集以及我的訓練方式下，XGBoost 有更好、更穩定的預測結果產生。

因此我選擇 XGBoost 當作我的模型並配合 BayesSearchCV 來找出最佳的參數組合。

## 2. 特徵工程 (Feature Engineering) 8 分

經過資料的觀察後發現這份資料中並沒有缺失值，因此沒有進行任何處理。

以下是我訓練的特徵工程步驟：

### 1. 整理數據：將視力及聽力的原始數據各自做整合

視力及聽力原始資料集都有分成左右耳（眼），

這部分將視力及聽力的數據轉換為，左邊為兩耳（眼）最佳，右邊為兩耳（眼）最差，來盡可能消除左右邊對於訓練的影響，因為理論上能夠影響的應該是最佳或最差的視力及聽力表現。並且在視力上有對明顯的異常值進行處理。

2. 新增四項醫學專有特徵：

BMI、血壓比、肝功能比、膽固醇比。

3. 接著分離數值特徵及類別特徵且各自做轉換：

數值特徵：

類別特徵以外的特徵，數值特徵有針對偏度大於 1 的去執行 log 轉換，將其偏度下降至稍微正常的範圍，執行完偏度轉換後對所有數值資料進行 Robust Scaler 的標準化。

類別特徵：

左耳聽力（最佳聽力）、右耳聽力（最差聽力）、蛀牙、尿蛋白、年齡前三項數值特徵為二元分類，使用 one-hot encoding；

尿蛋白有等級之分，使用 Label encoding；

年齡雖為數值，但其以每五年為區間，因此使用了 frequency encoding 多建構了年齡頻率的欄位。

雖然體重跟身高也是一樣的道理，但嘗試過後並未獲得更好的結果。

整體的執行順序為：

整理新增特徵、特徵分離、數值資料處理、類別資料處理。

4. 最後對所有處理後的特徵進行相關性計算，若有特徵兩兩關係大於 0.8 則移除特徵，使得計算的特徵共線性下降。

### 3. 交叉驗證與模型調整 (Cross-validation & Model Tuning) 5 分

我使用了 Stratified K-fold Cross-Validation：


```
cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
```

並使用 Bayesian Optimization 搭配 BayesSearchCV 來搜尋最佳超參數組合：


```
model = XGBClassifier(random_state=42, use_label_encoder=False, eval_metric='logloss')
param_space = {
    'learning_rate': Real(0.01, 0.3, prior='log-uniform'),
    'n_estimators': Integer(100, 500),
    'max_depth': Integer(3, 10),
    'subsample': Real(0.5, 1.0),
    'colsample_bytree': Real(0.5, 1.0),
    'min_child_weight': Integer(1, 10),
    'gamma': Real(0, 1.0),
    'reg_alpha': Real(0, 1.0),
    'reg_lambda': Real(0, 1.0),
    'scale_pos_weight': Real(1, 10)
}

cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)

opt = BayesSearchCV(
    model,
    search_spaces=param_space,
    cv=cv,
    n_iter=70,
    scoring='roc_auc',
    n_jobs=-1,
    random_state=42,
    verbose=0
)
```




#### 4. 模型表現與分析 (Model Performance & Analysis) 3 分




最終模型 AUC (Train) : 0.9400

我有比較了兩種：

# 1. XGBoost vs. LightGBM



## 2. 特徵是否最後還要選擇：SHAP 前 15、SHAP 自動選、全選



## 5. 結論與反思 (Conclusion & Reflection)

首先主要是訓練資源的問題，但這可以使用 Google Colab 及 Kaggle 上的免費 GPU 資源進行訓練。

接著是特徵處理上的問題，思考了很久到底該新增那些特徵，最後去參考曾經的比賽以及醫學上的知識查詢，在不亂加太多的情況下增加了四種醫學專業特徵。

在特徵轉換上，類別特徵可以使用 one-hot encoding 也有 Label 及 frequency encoder 可以使用，除了已知的 One-hot 不適合太多類別或造成資料維度大爆炸以外，其他的 encoding 方式也是試錯了很多次才找到最適合的方式。

最後是特徵提取的部分，在訓練前有使用相關係數去做特徵提取，但最後覺得好像不是很適合，一方面是我新增的兩個我認為很重要的醫學特徵剔除了，另一方面是對於 XGBoost 這種模型，似乎是沒有必要做這步驟的，他能妥善的處理共線性問題，但在反覆嘗試後，這是最佳的預測結果所以進行保留。

因此針對改進的部分，我認為可以適當的再思考該加入哪些有用的特徵，或甚至將一些特徵做平方的去強調之類的，並且可以嘗試老師這禮拜上課提到的 ensemble 模型去做試試看，不論是 stacking、voting...

而在調整參數的部分，可能可以根據BayesSearchCV 的結果去適當的放大或縮小尋找的範圍，或更甚至在資源足夠的情況下使用 GridSearch 去找到最佳參數。